


王颖	201722090323
黄孙培	201722090330
张敏	201721090111
刘胜男	201722090322
江润洲	201721090115



# **Image Segmentation Based on Statistics**

Wang Ying


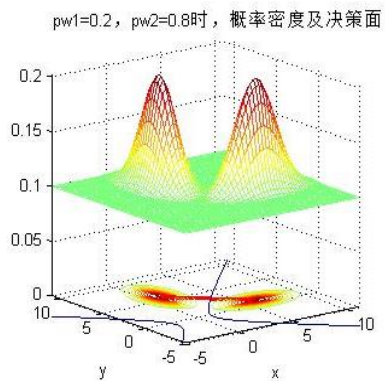
# 出发点






一维




value



多维



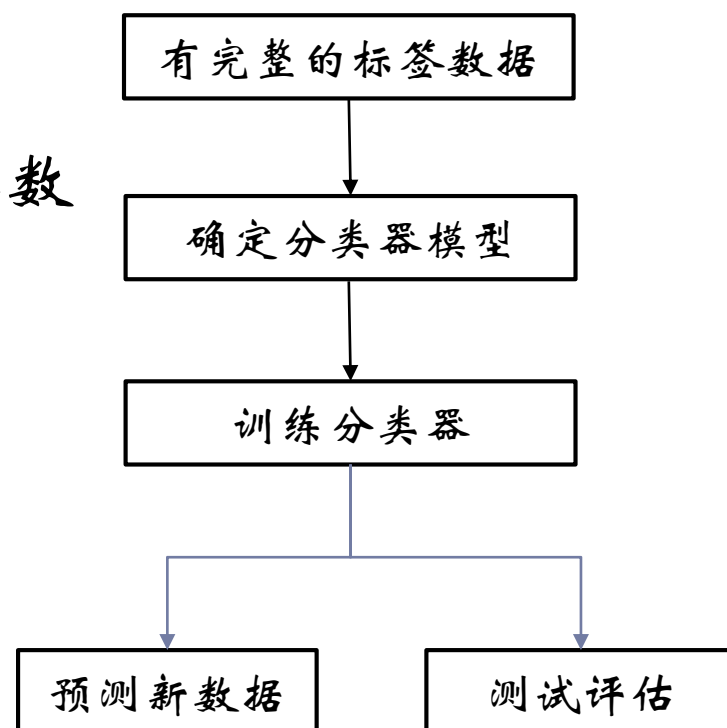
准确率为 0.94



Pixel Info (X, Y) Pixel Value


# Step of minimum error Bayes decision

- ▶ %% 读取图片及mask
- ▶ %% 读取训练集并画出分布
- ▶ %% 根据训练集计算两类分布的参数
- ▶ %% 根据训练集计算先验概率
- ▶ %% 计算新样本的条件概率
- ▶ %% 最大化后验概率分类
- ▶ %% 显示
- ▶ %% 性能评估




# 利用灰度信息做贝叶斯决策


灰度化的nemo



分割后的nemo



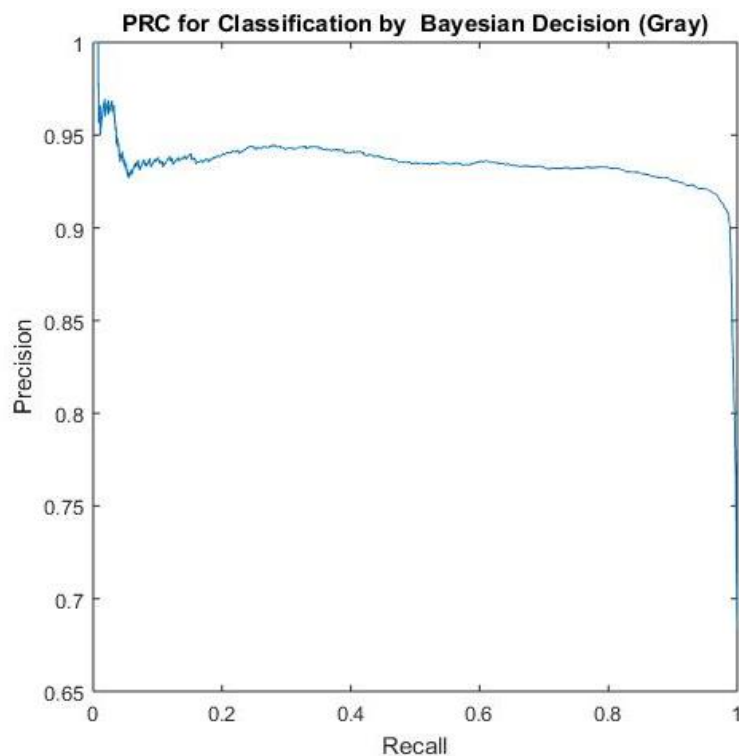
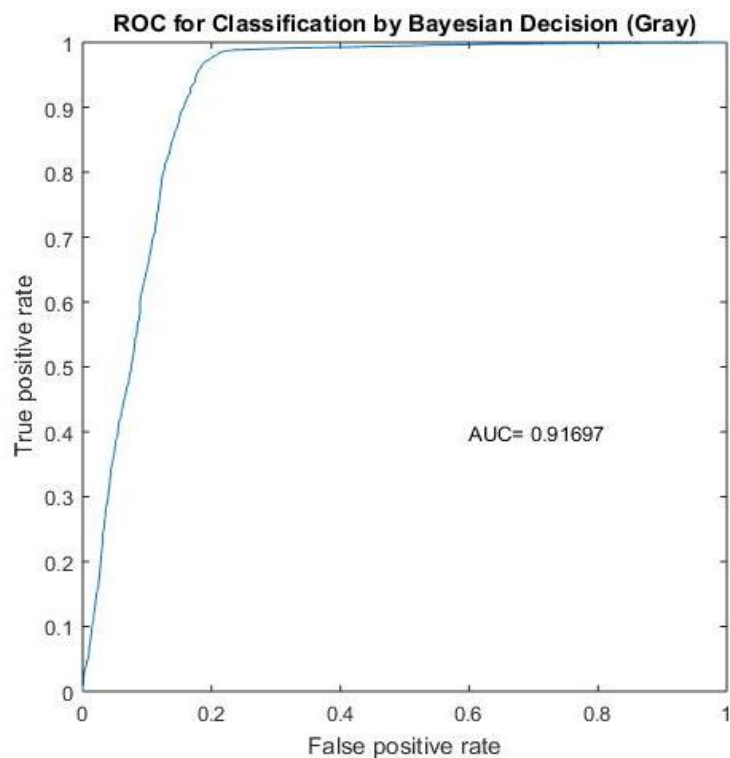
像素值分布



Pixel info: (X, Y) Pixel Value

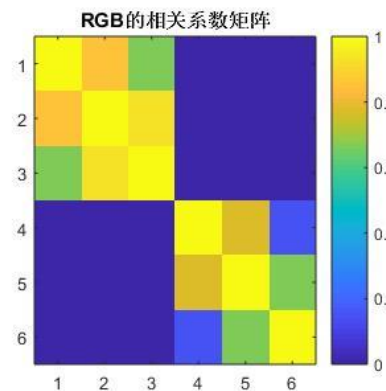
单通道分类信息量较少，由于反光等原因，可能造成某些高灰度像素误判成白色类别

# Performance





1. 训练集和测试集取了同一个
2. `pixel_score_test=logsig(post_P_test(white)-post_P_test(red));`  
对似然概率差值取了单极性sigmoid函数

# 利用RGB信息做贝叶斯决策



准确率为 0.94

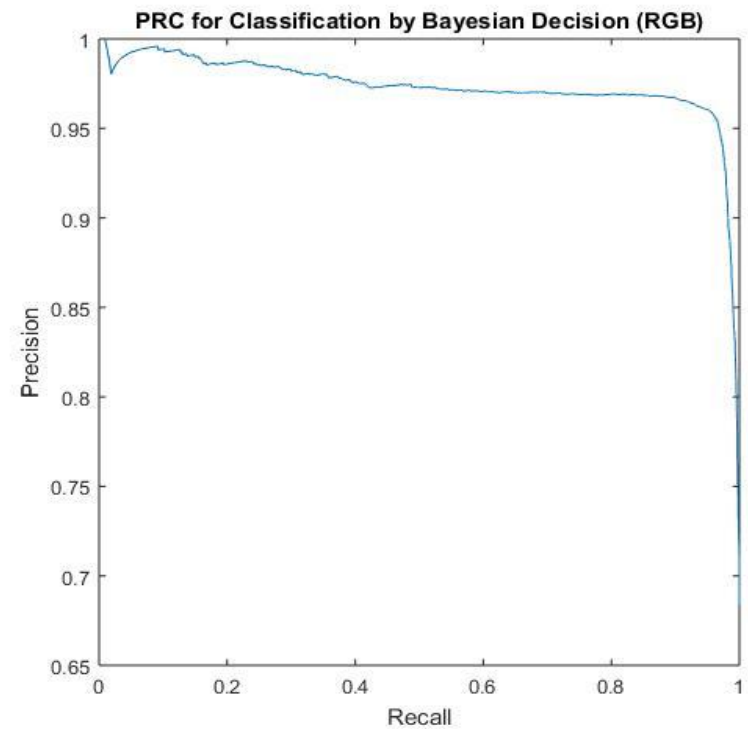



Pixel info: (X, Y) Pixel Value

由于红色类别的b分量一直很小，所以一旦b分量增大，  
就很可能跨越二次曲面决策面变为白色类造成误判

# Performance

---



# Expectation Maximization Cluster

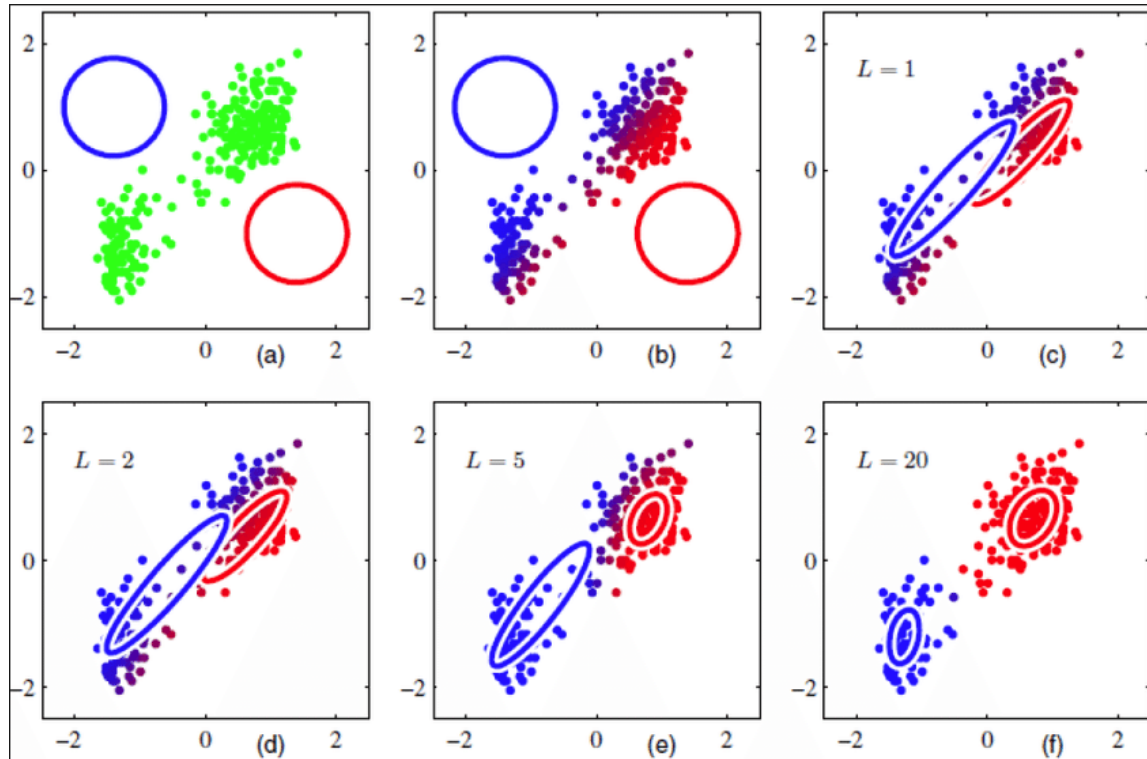
---

- ▶ %% 读取数据
- ▶ %% 数据分布类型->高斯分布 聚类类别->两类
- ▶ %% 设定初始参数->随机设置
- ▶ %% 循环迭代E步和M步，直至结束条件
  - ▶ %% E步（最小风险贝叶斯决策）：利用假设的参数和迭代算出的参数进行分类
  - ▶ %% M步（最大似然估计参数）：利用M步的结果算出给类别新的参数
  - ▶ %% 无法收敛、梯度不变或到达设定代数则退出
- ▶ %% 性能评估






# Expectation Maximization Cluster




$$\gamma^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$


# EM算法迭代过程




彩色的nemo




RGB的相关系数矩阵



分割后的nemo



聚类结果



Initial:

$$\mu = [100, 100, 100; 5, 5, 5] / 255;$$

$$\Sigma_{\text{red}} = \text{eye}(3) / 2;$$

Result:

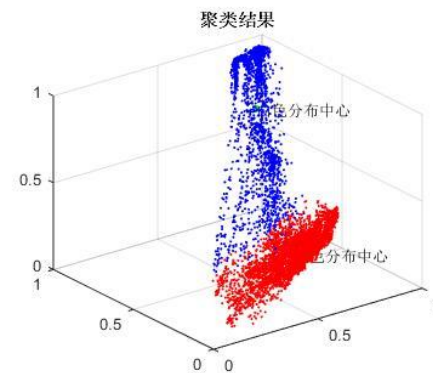



$$\mu = \begin{pmatrix} 195.4750 & 169.1837 \\ 186.5966 & 92.2304 \\ 198.8544 & 38.1178 \end{pmatrix}$$

$$\mathbf{r}_{\text{white}} = \begin{pmatrix} 1.0000 & 0.8734 & 0.6894 \\ 0.8734 & 1.0000 & 0.9205 \\ 0.6894 & 0.9205 & 1.0000 \end{pmatrix}$$

$$\mathbf{r}_{\text{red}} = \begin{pmatrix} 1.0000 & 0.8991 & 0.3234 \\ 0.8991 & 1.0000 & 0.5902 \\ 0.3234 & 0.5902 & 1.0000 \end{pmatrix}$$

►  $\Sigma_{\text{white}} = \text{eye}(3) / 2;$

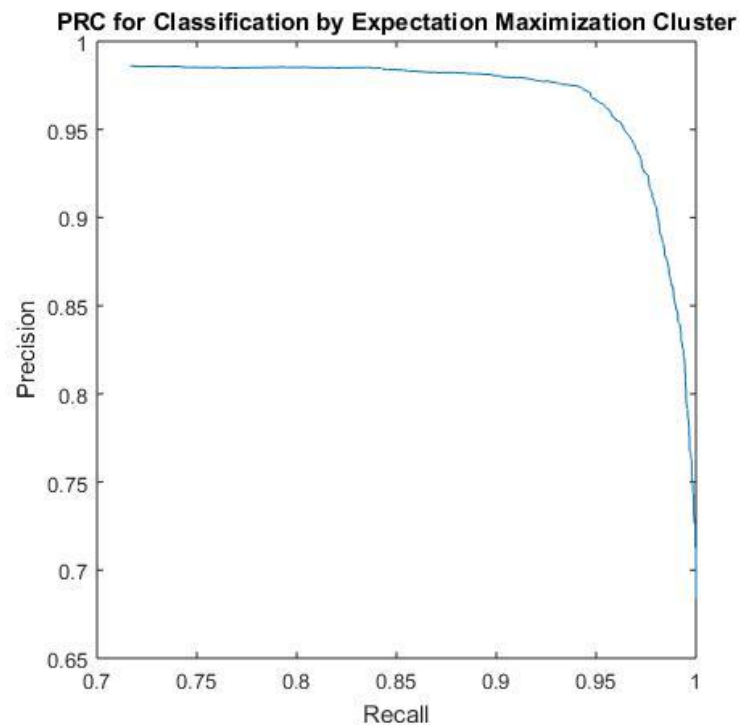
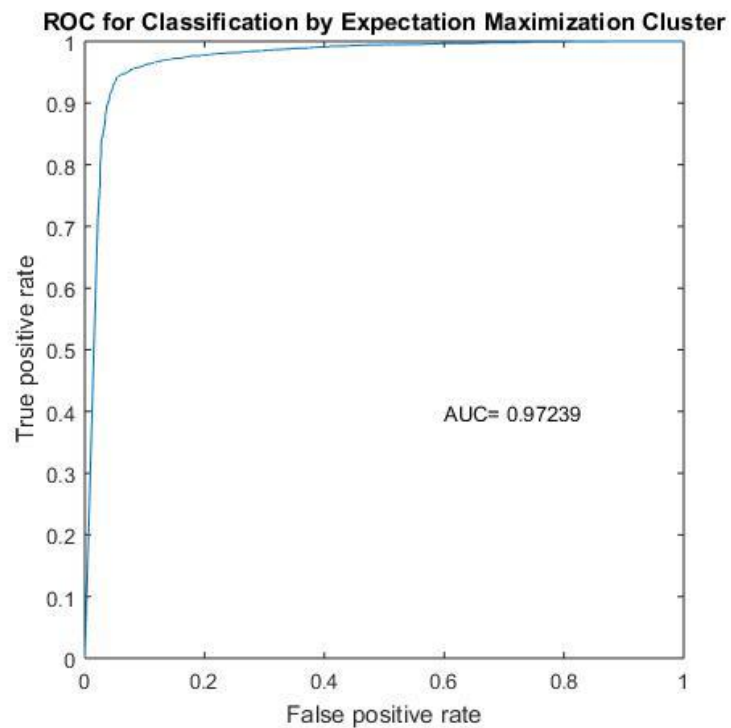
# EM算法迭代结果



Pixel info: (X, Y) Pixel Value

EM算法收敛不断利用假设及迭代出来的参数计算似然函数的下界

# Performance









由于EM相当于是按照threshold=0.5迭代的，所以最佳阈值在0.5附近很小的范围里

```
pixel_score_test=logsig(post_P_test(white)-post_P_test(red));
```

# Comparison

从ROC看EM算法得到的分类器AUC最大，分类性能最好  
从PR曲线上可以比ROC更明显地看出，只利用灰度信息进行分类的效果  
不如三通道进行分类



# Why EM algorithm can converge?

似然函数变形:



$$\sum_i \log p(x^{(i)}; \theta) = \sum_i \log \sum_{z^{(i)}} p(x^{(i)}, z^{(i)}; \theta) \quad (1)$$

$$= \sum_i \log \sum_{z^{(i)}} Q_i(z^{(i)}) \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} \quad (2)$$

$$\geq \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} \quad (3)$$

Jensen不等式:

$$E[f(X)] \geq f(E[X])$$



固定 $\theta$ , 调整 $Q(z)$ 使下界 $J(z, Q)$ 上升至与 $L(\theta)$ 在此点 $\theta$ 处相等, 然后固定 $Q(z)$ , 调整 $\theta$ 使下界 $J(z, Q)$ 达到最大值, 此时为新的 $\theta$ , 再固定 $\theta$ , 调整 $Q(z)$ ……直到收敛到似然函数 $L(\theta)$ 的最大值处的 $\theta^*$

# 遗留问题

- ▶ 初值设置严格规律
- ▶ 没做三元高斯函数的概率密度函数可视化，应该可以画出等值椭球面。
- ▶ \*决策面方程没找到解的方法，好像歪歪扭扭在搞

$$\mathbf{x}^T(\mathbf{W}_i - \mathbf{W}_j)\mathbf{x} + (\mathbf{w}_i - \mathbf{w}_j)^T\mathbf{x} + w_{i0} - w_{j0} = 0$$

$$\mathbf{x}^T \mathbf{W} \mathbf{x} + \mathbf{w}^T \mathbf{x} + c = 0$$

$$\mathbf{x}^T \mathbf{W} \mathbf{x}' = 0$$

$$(\mathbf{x}'^T \mathbf{u}^T)(\mathbf{u} \mathbf{x}') = 0$$

$$\Sigma_i \neq \Sigma_j, \quad i, j = 1, 2, \dots, c \quad (2-90)$$

判别函数式(2-66)只有第二项 $\frac{1}{2} \ln 2\pi$ 与 $i$ 无关,可忽略,简化后得

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \\ &= \mathbf{x}^T \mathbf{W}_i \mathbf{x} + \mathbf{w}_i^T \mathbf{x} + w_{i0} \end{aligned} \quad (2-91)$$

其中

$$\mathbf{W}_i = -\frac{1}{2} \Sigma_i^{-1} \quad (d \times d \text{ 矩阵}) \quad (2-92)$$

$$\mathbf{w}_i = \Sigma_i^{-1} \mu_i \quad (d \text{ 维列向量}) \quad (2-93)$$

$$w_{i0} = -\frac{1}{2} \mu_i^T \Sigma_i^{-1} \mu_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \quad (2-94)$$

这时判别函数式(2-91)将 $g_i(\mathbf{x})$ 表示为 $\mathbf{x}$ 的二次型。若决策域 $\mathcal{R}_i$ 与 $\mathcal{R}_j$ 毗邻,则决策面应满足

$$g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$$

即

$$\mathbf{x}^T(\mathbf{W}_i - \mathbf{W}_j)\mathbf{x} + (\mathbf{w}_i - \mathbf{w}_j)^T\mathbf{x} + w_{i0} - w_{j0} = 0 \quad (2-95)$$

由式(2-95)所决定的决策面为超二次曲面,随着 $\Sigma_i, \mu_i, P(\omega_i)$ 的不同而呈现为某种超二次曲面,即超球面、超椭球面、超抛物面、超双曲面或超平面。图2-11示出了在二元正态情况下决策面的形式,在图2-11(a)~(e)五种形式中,变量 $x_1$ 和 $x_2$ 是类条件独立的,所以协方差矩阵为对角阵。如果再假定各先验概率相等,那么不同的决策面只是由于方差项的差异而引起的。




图 2-11 正态分布下的几种决策面形式

图中以标号1,2的等概率密度轮廓线来表征相应类别的方差,在图2-11(a)中, $p(\mathbf{x}|\omega_1)$ 的方差比 $p(\mathbf{x}|\omega_2)$ 小,因此来自类 $\omega_1$ 的样本更加可能在该类的均值附近找到,同时由于圆的对称性,决策面是包围着 $\mu_1$ 的一个圆。若把 $x_2$ 轴伸展,如图2-11(b)所示,此时决策面就

# Thank you !

---

- ▶ 很多实验都是横向的知识迁移，所以希望来自不同领域的大家能够相互交流减少重复劳动吧。
- ▶ 比如工具的安装和验证可行性、资料的重复查找，虽然过程也是在锻炼，但是即便熟练的人也会有很多重复工作，如果能相互分享经验和有趣的想法或技巧，也算是我们的工作吧。

